

基于光谱时序分割的矿区植被生态时序监测

摘要：矿区植被随着露天开采的进行往往会发生时空动态变化，其是矿区监管和环境可持续性评估的必要信息。为了获取矿区植被在空间范围和干扰-恢复模式上的动态信息，本文发展了一种基于光谱时序分割的矿区植被生态时序监测方法，以美国犹他州盐湖城的宾汉峡谷矿区为研究区，基于谷歌地球引擎（GEE）构建 1972-2022 年经去云、校正、编码等预处理步骤的高质量时序影像集，为降低噪声影响并进一步探测矿区扰动，基于光谱时序分割算法利用像素年度轨迹重建植被的时间演变，识别突变信息，生成突变事件发生的年份、持续时间和幅度等变化地图，进一步分析轨迹的干扰-恢复模式，并基于形状特征对分割后的轨迹数据进行聚类 and 深度学习分类，生成轨迹聚类和分类地图。考虑到光学影像的局限性，结合 Sentinel-1 数据，将时间序列分解为若干区间，并对每个区间应用似然比检验来检测有序序列 SAR 图像中的变化，生成生产活动监测地图。研究结果表明，变化地图可以有效检测出中高强度的扰动事件，聚类与分类地图能够较好地概括研究区的生态干扰-恢复模式，监测地图表明宾汉峡谷矿区依旧保持较高强度的开采活动。

关键词：矿区、时间序列、轨迹、聚类、分类、变化监测

1. 引言

时间序列数据由固定点位在不同时间的特征值观测组成，以时间作横轴，特征值为纵轴，从而追踪特定点的特征变化^[1]。

对于矿区生态时序监测而言，地表植被的状态是衡量生态健康状况的关键指标^[2]。植被变化量化了开采活动的生态影响，常用的监测指标包括归一化植被指数（NDVI）、增强型植被指数（EVI）、归一化差异湿度指数（NDMI）、缨帽变换绿度指数（TCG）、湿度指数（TCW）等，其中 NDVI 使用最为广泛，对于 Landsat 系列卫星，缨帽变换方法已非常成熟。如图 1，研究区某点位的 NDVI 时序数据呈现出“稳定-干扰-恢复”的典型模式，通过深入分析不同点位的变化趋势，可以有效评估该区域生态变化状况。

由于植被扰动与恢复在空间和时间上的广泛性使其动态监测充满挑战^[3-5]。而传统地面监测因成本问题多限于小规模和低频次，不足以全面理解矿区扰动和自然恢复过程^[6,7]。近几十年来，国内外提出了许多变化检测方法，大致分为 3 大类：1）轨迹拟合法，如 TBCD 算法^[8,9]，它基于预设的变化轨迹类型，通过最小二乘法匹配像元变化；2）光谱-时序分割法，如 VCT、LandTrendr 算法^[10-12]，依据光谱时间轨迹特征，通过阈值或参数设定确定变化类型；3）基于模型的方法，如 BFAST、CCDC 算法^[13,14]，通过设定时间变化模型进行变化检测。




图1 宾汉峡谷矿区点位植被生态监测示意图

由于 LandTrendr 可捕捉年度变化信息和拟合轨迹数据，并集成于谷歌地球引擎（GEE）平台，可有效缩减数据获取与处理的时间成本。因此，本文在 GEE 平台合成 NDVI、TCG、TCW 波段，应用光谱时序分割提取矿区植被扰动的空间和时间特征，通过聚类 and 深度学习分类，生成轨迹聚类和分类地图，结合 Sentinel-1 数据，检测有序序列 SAR 图像中的变化，生成生产活动监测地图，监测并评估开采活动对生态环境的扰动影响，为矿区生态管理和恢复提供科学依据。

2. 研究区概况

宾汉峡谷矿区坐落于美国犹他州盐湖城附近的奥克尔山脉，北纬 40.49426° 至 40.54646° ，西经 112.10258° 至 112.17948° 。矿区深达 1210 米，宽 4000 米，总面积 7.7 平方公里。自 1906 年起，该矿便开始进行采矿活动，距今已有近 120 年历史。尽管主矿区在 2013 年已宣布开采完毕，但露天与地下开采活动仍在持续扩张。

与工业时代的其他采矿作业相似，宾汉峡谷矿区对当地野生动物栖息地产生负面影响，并导致空气与水体污染，对周边居民健康构成威胁。1990 年起，已投资超过 4 亿美元进行环境修复。为此，以宾汉峡谷矿区为研究区，开展基于光谱时序分割的矿区植被生态时序监测具有重要研究意义，对我国露天矿区植被生态监测亦有借鉴意义。




图 2 研究区地理位置示意图

3. 研究方法

本节介绍所开展的矿区生态时序监测方法，其框架如图 3 所示。在数据源部分，需确保 Landsat 系列卫星不同传感器和不同时间获取的影像数据在地表反射率和云层掩膜方面具有一致性和可比性。在保证变化检测时序数据具备同质性前提下，对兴趣波段进行光谱时序分割以提取干扰信息与拟合轨迹。进一步分析干扰信息绘制变化地图，基于拟合轨迹形状特征进行聚类与分类处理，绘制聚类与分类地图。考虑到光学影像的局限性，结合 SAR 时序数据，通过将时序分解为若干区间，并对每个区间应用似然比检验来检测有序序列图像中的变化以监测矿区的生产活动。

3.1 LandTrendr 光谱时序分割

在数据获取和处理阶段，基于 GEE 平台获取 Landsat 影像数据集，进行解压、堆叠和重投影处理，转换地表反射率、大气顶反射率；结合 DEM 数据识别云层和云影，掩膜云层；协调 MSS、TM/ETM+、OLI 传感器，归一化反射率，最后合成年度影像。

对时序影像集合上每个像素的光谱轨迹进行光谱时序分割，通过去噪、顶点识别、回归统计分析，用直线段来模拟轨迹的重要特征，分割出直线段端点的时间和光谱值，拟合轨迹，以便理解数据的变化趋势并为生成变化图提供所需的基本数据。




图 3 技术流程图

3.2 KShape 聚类

对拟合后的轨迹数据，可以通过变化趋势了解研究区的生态变化类型。轨迹数据带有时间信息，因此，可以将其视作时序数据处理。

在本文中，专注于时间序列数据的形状匹配，而非单纯的数值匹配。这一需求使得传统的数值聚类算法，如 KMeans 和 KNN 等不再适用。为此，我们引入了 KShape 算法^[15]，其专注于识别形状相似的时间序列。其原理与 KMeans 相似，但对距离度量和质心计算方法进行了重要的改进，能有效地对时间序列进行形状聚类，同时可以对多特征时序数据聚类，这对综合分析轨迹变化趋势具有重要意义。本文分别对一维（NDVI）与三维（NDVI、TCG、TCW）时序数据进行聚类。

在聚类分析中，K-Elbow 法则^[16]是确定最优聚类数量 k 的常用方法。通过绘制不同 k 值对应的度量值变化曲线，寻找曲线拐点，即“肘部”，作为 k 值的选择依据。本文根据实验结果与实际情况，选取单元聚类 k 为 4，多元聚类 k 为 5。

3.3 深度学习分类

KShape 算法无需先验知识即可聚类时序数据，但其对 k 值敏感，时间复杂度较高，制图过程相对复杂。为了克服这些限制，并进行更具代表性和泛化能力的时序分析，我们引入深度学习分类技术。与传统遥感时序分类^[17]不同，本分类任务并非识别地物，而旨在依据时序变化趋势判别像素点的生态干扰-恢复模式。

3.3.1 数据集创建

UCR TSCA 拥有 128 个时间序列分类数据集。其中的“Stimulated”标签显示了合成数据集的应用价值。例如，SyntheticControl 包含 600 条人工合成时序，分为 6 类；Zhen Yang 等^[18]则开发了 7 种矿区干扰曲线模板。为避免归一化过程中的轨迹数据失真，基于 NDVI 变化曲线建立包含 6 个类别的分类数据集（图 4）：1）干扰；2）干扰后恢复；3）恢复；4）恢复时干扰；5）稳定；6）多次干扰。为降低主观影响并提高模型泛化能力，向数据中引入随机噪声和变化趋势，手动移除一些不理想的数据，得到 1379 条数据。




图 4 数据集说明

3.3.2 模型训练与分类

模型部分，本文选择 InceptionTime 模型进行训练与分类，该模型作为时序分类问题的最新监督深度学习方法^[19]，对时序数据具有良好的结构和特征信息提取能力；同时选择 TimeSeriesTransformer 模型^[20]作为对比分析。以上两种模型都将时序数据视为数值数据处理，但人脑更倾向于图像化来识别时序数据的趋势。在计算机视觉中，图像的矩阵表示使得时序数据的图像化转换成为可能。本文对六种主流图像化结果（图 5）均使用 xresnet34 网络^[21]进行了训练实验，图 6 表明在协调精度与效率情况下，格拉米安角差场变换方法^[22]最为合适。




图 5 一维时序数值转二维图片




图 6 格拉米安角差场时序图像训练损失与准确率

3.4 开采活动变化监测

鉴于宾汉峡谷矿区的长期开采历史及其已成型的地貌特征，该矿区的露天部分持续保持裸露状态。尽管开采活动持续进行，但光学影像由于其固有的局限性，难以准确捕捉到这些动态变化。特别是对于工程车辆的流量和重型机械的作业情况，这些细微变化在光学影像上往往不显著。

相比之下，Sentinel-1 号卫星凭借其 10m 的空间分辨率与 6 天的重访周期，提供了有效的替代方案。它能够捕捉到工程车辆流量的变化和重型机械建设活动的动态，是评估矿区开采活动的关键因素。由 3.1 小节对获取的干扰年份信息处理得到图 7，展示研究区所有受干扰像素的干扰年份的频率分布。虽 1985 年干扰最频繁，但 Sentine-1 于 2014 年 4 月 3 日发射，则选取该时间之后的数据，本文选取 2019 年 4 月至 2020 年 11 月作为研究区间。




图 7 干扰年份频率分布直方图

获取时间区间内的 49 幅轨道上升模式下的 GRD 数据。使用 Sequential Omnibus Test 统计方法^[23]，通过将时间序列分解为若干区间，并对每个区间应用似然比检验来检测有序序列 SAR 图像中的变化。对于每个区间，利用卡方分布计算检验统计量和显著水平的 P 值，迭代 P 值输出生产活动监测地图。

4. 结果与分析

4.1 矿区总体变化趋势

为了方便验证变化趋势，图 8 将研究区分为 4 部分。截取研究区在 1972 年至 2022 年间部分年度合成影像集 NDVI 波段，图 9 显示，矿区在这 51 年间持续展现出扩张趋势，特别是 1 号矿区与主矿区东部地区，这一现象尤为显著；主矿区正中部有恢复-干扰趋势；1 号矿区持续干扰趋势；2 号矿区有干扰-恢复趋势；3 号矿区有恢复趋势。




图 8 矿区分布示意






图 9 NDVI 时序变化图

4.2 基于光谱时序分割的矿区扰动和变化地图结果分析


变化地图（图 10）表明主要的干扰出现在 1 号矿区及主矿区西部边缘，其受干扰时间最早；干扰年份集中在 90 年代末和世纪初，其变化幅度较大（NDVI 扰动在 0.3~0.5 之间），且干扰持续时间不一（2~10 年间），变化率较大；1、2 号矿区受干扰前 NDVI 值低于 0，说明变化前矿区已受过干扰，主矿区西部变化前 NDVI 大于 0.41，说明变化前该区域生态稳定，为首次重大生态扰动，而 1 号矿区可能发生多次扰动，2 号矿区则有恢复趋势。结合 Google Earth 历史影像对比，上述变化可以得到有效验证，但 2017 年至 2022 年间，3 号矿区有生态恢复的迹象，变化地图中却没有充分展示。




a) 干扰年份地图




b) 绝对变化幅度地图




c) 持续时间地图



d) 光谱变化率地图



e) 干扰前 NDVI 值分布地图



f) 校正幅度地图

图 10 变化地图

4.3 基于拟合轨迹形状的聚类结果分析

4.2 小节通过光谱时序分割提取矿区干扰信息，本质上是在时序数据中提取异常值。本小节将时序数据视作整体，从整个时间尺度上分析生态变化趋势。

单元聚类结果（图 11）揭示了类别 4 在研究区域中的普遍性，其高比例表明该区域主要呈现稳定状态。多元聚类结果（图 12）亦呈现相似趋势，特别地，在 3 号矿区中，类别 5 的出现尤为显著，表明了生态恢复的迹象。此外，无论是单元聚类还是多元聚类，在主矿区的中西部均检测到明显的干扰迹象，这与 4.1 小节结论一致。

进一步分析显示，多元聚类中 3 号矿区的类别 5 指向了生态恢复的趋势，而单元聚类则在 2 号矿区识别出了从干扰到恢复的过渡迹象，归类为类别 3。表明 4.2 小节中变化地图未能明显展示的生态恢复迹象，在聚类分析中得到了体现。




图 11 单元 (NDVI) 聚类地图




图 12 多元 (NDVI、TCG、TCW) 聚类地图

4.4 基于深度学习分类的结果分析

鉴于聚类分析的局限性，采用 3.3 节所述的深度学习方法进行分类。分类结果显示：InceptionTime (图 13) 较 TimeSeriesTransformer (图 14) 更为精确，尤其是在识别生态恢复趋势方面。另外 xresnet34 模型在数据集层面达到了最佳精度 (表 1)，但其在影像分类上的表现并不理想 (图 15)。

对于主矿区边界，二者分类结果相似；在其正中部，均揭示了恢复与干扰的变化趋势，且与实际相符。InceptionTime 在 1 号矿区北部未能有效识别其干扰-恢复趋势，而 TimeSeriesTransformer 表现更佳。在 2 号矿区，两种方法均监测到生态干扰后的恢复迹象。在 3 号矿区，InceptionTime 分类结果更为精确，能够明确识别生态恢复趋势，并清晰界定生态恢复区域边界；而 TimeSeriesTransformer 虽也识别出生态恢复趋势，但其范围过大，边界模糊。




图 13 InceptionTime 分类地图




图 14 TimeSeriesTransformer 分类地图




图 15 xresnet34 分类地图

4.5 聚类、分类精度验证

目视解译结果虽直观，但主观性较强，需通过精度评估验证。本文采用随机抽样验证方案，人工独立验证后，结果列于表 1。数据显示，InceptionTime 精度最高，TimeSeriesTransformer、KShape 次之，最低为 xresnet34。


表 1. 精度验证

分类/聚类器	验证集精度	测试集精度	实际精度
InceptionTime	0.9891	0.9910	0.8625
TimeSeriesTransformer	0.9855	0.9742	0.8210
KShape(univariate)	N/A	N/A	0.7240
Xresnet34	0.9928	0.9732	0.5725


4.6 矿区开采活动监测结果分析

4.3 与 4.4 小节均显示主矿区趋于生态稳定，这归因于地表长期裸露，植被指数等特征未能有效反映变化。因此需结合 SAR 影像综合分析。


生产活动监测结果见图 16，其值域 $\in[0, k-1]$ ， k 为影像数，本例中 $k=49$ ，值越小说明变化越接近时间轴起点，反之亦然。结果表明，主矿区在研究期间保持了高密度生产活动，特别是在 2020 年末，中部、北部和东部边缘区域活动尤为集中。西南方向与 1 号矿区交界处的开发频率最高。2019 年 4 月，正定变化比例的显著增长表明了大规模生产活动的进行；至 2019 年末，负定变化比例上升，反映了生产活动强度的减缓。




a) 最近一次变化地图




b) 首次变化地图



c) 变化次数地图



d) 假彩色合成



e) 正定、负定、不定变化比例图

图 16 生产活动监测图

5. 结论

本文主要发展了一种基于光谱时序分割的矿区植被生态监测方法。其涵盖从数据获取、处理、聚类、分类、精度评价、SAR 变化检测到遥感制图的全过程，所有步骤均通过云平台和编程实现，确保了高效性和可扩展性。该方法不仅提高了矿区生态监测的效率和精度，而且通过集成多种遥感技术和方法，为矿区生态管理和决策提供了有力的科学支持。

参考文献(References)

- [1] LEE H. Mapping Deforestation and Age of Evergreen Trees by Applying a Binary Coding Method to Time-Series Landsat November Images [J]. IEEE Transactions on Geoscience and Remote Sensing, 2008, 46: 3926-36.
- [2] 李晶, 焦利鹏, 申莹莹, et al. 基于 IFZ 与 NDVI 的矿区土地利用/覆盖变化研究 [J]. 煤炭学报, 2016, (11).
- [3] AWUAH-OFFEI K, ADEKPEDJOU A. Application of life cycle assessment in the mining industry [J]. The International Journal of Life Cycle Assessment, 2011, 16: 82-9.
- [4] WANG J, WANG H, CAO Y, et al. Effects of soil and topographic factors on vegetation restoration in opencast coal mine dumps located in a loess area [J]. Scientific Reports, 2016, 6.
- [5] LECHNER A, MCINTYRE N, WITT K, et al. Challenges of integrated modelling in mining regions to address social, environmental and economic impacts [J]. Environmental Modelling and Software, 2017, 93.
- [6] LECHNER A, ARNOLD S, FLETCHER A, et al. Embracing modern ecological methods: Monitoring and modelling for mine closure not compliance [M]. 2012.
- [7] BAO N, LECHNER A, FLETCHER A, et al. SPOTting long-term changes in vegetation over short-term variability [J]. International Journal of Mining, Reclamation and Environment, 2012, 28: 1-23.
- [8] KENNEDY R, COHEN W, SCHROEDER T. Trajectory-based change detection for automated characterization of forest disturbance dynamics [J]. Remote Sensing of Environment, 2007, 110: 370-86.
- [9] AHMED O, FRANKLIN S, WULDER M. Interpretation of forest disturbance using a time series of Landsat imagery and canopy structure from airborne lidar [J]. Canadian Journal of Remote Sensing, 2014, 39: 521-42.
- [10] HUANG C, GOWARD S, MASEK J, et al. An automated approach for reconstructing recent forest disturbance history using dense Landsat time series stacks [J]. Remote Sensing of Environment, 2010, 114: 183-98.

- [11] KENNEDY R E, YANG Z, COHEN W B. Detecting trends in forest disturbance and recovery using yearly Landsat time series: 1. LandTrendr — Temporal segmentation algorithms [J]. Remote Sensing of Environment, 2010, 114(12): 2897-910.
- [12] KENNEDY R, YANG Z, BRAATEN J, et al. Attribution of disturbance change agent from Landsat time-series in support of habitat monitoring in the Puget Sound region, USA [J]. Remote Sensing of Environment, 2015, 166: 271-85.
- [13] ZHU Z, WOODCOCK C. Continuous Change Detection and Classification of Land Cover Using All Available Landsat Data [J]. Remote Sensing of Environment, 2013, 144.
- [14] KHAN S, SASS O, SAMIMI C. Detecting change in Landsat time series with BFAST in the eastern Hindu Kush region [M]. 2020.
- [15] PAPARRIZOS J, GRAVANO L. k-Shape: Efficient and Accurate Clustering of Time Series [J]. ACM SIGMOD Record, 2016, 45: 69-76.
- [16] HAMKA M, RAMDHONI N. K-Means cluster optimization for potentiality student grouping using elbow method [M]. 2022.
- [17] 何瑞. 基于时间序列光学遥感影像的多云雾山区树种分类方法研究 [D]; 电子科技大学, 2024.
- [18] YANG Z, LI J, ZIPPER C, et al. Identification of the disturbance and trajectory types in mining areas using multitemporal remote sensing images [J]. Science of the Total Environment, 2018, 644: 916-27.
- [19] ISMAIL FAWAZ H, LUCAS B, FORESTIER G, et al. InceptionTime: Finding AlexNet for time series classification [J]. Data Mining and Knowledge Discovery, 2020, 34: 1-27.
- [20] ZHU S, ZHENG J, MA Q. MR-Transformer: Multiresolution Transformer for Multivariate Time Series Prediction [J]. IEEE transactions on neural networks and learning systems, 2023, PP.
- [21] RAYHAN A, KINZLER R, RAYHAN R. DEEP RESIDUAL LEARNING FOR IMAGE AND VIDEO RECOGNITION [M]. 2023.
- [22] PAN X, YU Z, YANG Z. A deep learning multimodal fusion framework for wood species identification using near-infrared spectroscopy GADF and RGB image [J]. Holzforschung, 2023, 77: 816-27.
- [23] SAMORODNITSKY S, CAMPBELL K, RIBAS A, et al. A Spatial Omnibus Test (SPOT) for Spatial Proteomic Data [M]. 2024.